

ML4hydromet-2025

Занятие №2.

Технические средства анализа данных.

Разведочный анализ данных.

Преподаватели:

Михаил Иванович Варенцов, к.г.н.

Михаил Алексеевич Криницкий, к.т.н.

ml4hydromet@ml4es.ru



Репозиторий курса

ML4hydromet-2025

Курс "Машинное обучение в гидрометеорологии" для магистров I года обучения географического факультета МГУ.

Читают Михаил Варенцов ([ИСТИНА](#), [ResearchGate](#)) и Михаил Криницкий ([персональная страница](#), [ResearchGate](#)).

Предыдущая версия курса [ML4hydromet-2024](#)

Материалы по курсу

Название	Дата	Тема	Материалы
Лекция 1a	06.10.2025	Орг. вопросы Введение в машинное обучение	видеозапись материалы: слайды-1 материалы: слайды-2
Лекция 16	06.10.2025	Введение в машинное обучение	видеозапись материалы: слайды-1 материалы: слайды-2

[https://github.com/mvarentsov/
ML4hydromet-2025](https://github.com/mvarentsov/ML4hydromet-2025)



Краткое введение в Git

- ❑ Git - система управления версиями
- ❑ Придумал Линус Торвалдс при разработке ядра Линукс
- ❑ Современный стандарт для совместной разработки, в том числе в научной сфере и Data Science
- ❑ Задачи Git:
 - Синхронизация
 - Резервное копирование
 - Отслеживание и отмена изменений
 - Командная работа

Имя	Дата изменения	Тип	Размер
all_exel_v5	19.06.2022 21:15	Папка с файлами	
all_exel_v6	19.06.2022 21:15	Папка с файлами	
Model_v2	19.06.2022 21:15	Папка с файлами	
Model_v3	19.06.2022 21:16	Папка с файлами	
Model_v4	19.06.2022 21:16	Папка с файлами	
Model_v5	19.06.2022 21:16	Папка с файлами	
Model_v5h	19.06.2022 21:16	Папка с файлами	
Model_v6	19.06.2022 21:16	Папка с файлами	
Model_v7	19.06.2022 21:16	Папка с файлами	
Model_v7_1	19.06.2022 21:16	Папка с файлами	
Model_v7_2exp	19.06.2022 21:16	Папка с файлами	
to do wiith model	29.11.2012 2:06	Файл "TXT"	1 КБ
to do	04.06.2013 10:38	Файл "TXT"	1 КБ
история изменений	01.06.2013 23:07	Файл "TXT"	1 КБ


Краткое введение в Git

- ❑ **Репозиторий** — место, где хранится код (или данные)
 - Локальный
 - Удаленный (remote)
- ❑ **Коммит (commit)** — зафиксированное и неизменяемое состояние репозитория. Чаще всего их создают, когда:
 - Создан новый функционал
 - Добавлен новый блок на верстке
 - Исправлены ошибки по коду
 - Завершен рабочий день
- ❑ **Ветка (branch)** - независимая последовательность коммитов в хронологическом порядке



Краткое введение в Git

- ❑ **git clone** – получения локальной копии существующего Git-репозитория
`git clone git@github.com:mvarentsov/ML4hydromet-2025.git`
- ❑ **git fetch** – загрузка содержимого из удаленного репозитория (без изменения локального репозитория)
- ❑ **git pull = Git fetch + Git merge** – загрузка содержимого из удаленного репозитория и обновление локального репозитория
- ❑ **git add** – добавить файл в список тех, которые отслеживаются для текущего коммита
- ❑ **git commit** – зафиксировать текущие изменения
- ❑ **git push** – выгрузка содержимого локального репозитория в удаленный репозиторий.



In case of fire



1. git commit
2. git push
3. exit building

Графические интерфейсы для Git

❑ GitHub – облачный Git-сервер


- Альтернатива – создать собственный сервер, например на базе GitLab

❑ GitHub Desktop – графический клиент для GitHub.

❑ Интеграции во многие современные IDE

❑ Есть и альтернативы

- Sourcetree (Windows, macOS и Linux)
- GitKraken (Windows, macOS)
- ...




Python для анализа данных

Почему Python?

TIOBE Programming Community Index


Source: www.tiobe.com



Рейтинг TIOBE (TIOBE Index) — это ежемесячный индекс, который отражает популярность языков программирования. Он основан на количестве поисковых запросов в различных поисковых системах, таких как Google, Bing, Yahoo!, Wikipedia и других.



Экосистема Python

- ❑ Python – один из интерпретируемых языков программирования (наряду с R, Matlab, Julia и др.).
 - Исполняется ровно точно то, что написано
 - Исполняется построчно
 - Ошибки идентифицируются только в момент исполнения
- ❑ Ключевые элементы экосистемы:
 - **Дистрибутив Python** (например Anaconda)
 - **Среда выполнения:** python (встроенная), ipython, Jupiter notebook, Google Colab и пр.
 - **Среды разработки (IDE):** VS Code, PyCharm, Spyder, Jupiter Lab и пр.
 - **Пакетный менеджер** (pip, conda)
 - **Окружение (environment)**



Jupyter Notebook

- ❑ Поддержка разных языков программирования (Ju-Py-teR = Julia, Python & R, и не только) через механизм ядер (kernels)
 - Ядро — это отдельная запущенная программа-интерпретатор (например, Python), которая выполняет код из ячеек, хранит в памяти все переменные
- ❑ Поэтапное и нелинейное исполнения (важно об этом помнить)
- ❑ Комбинирование контента: объединение вместе исходного кода, результатов его выполнения, повествовательный текст (с использованием Markdown), формулы (LaTeX) и др.
- ❑ Интерактивные графики и элементы
- ❑ Платформонезависимость, поддержка разными IDE
- ❑ Поддержка команд bash shell в коде python (jupyter magic)



nature

[Explore content](#) ▾ [About the journal](#) ▾ [Publish with us](#) ▾ [Subscribe](#)

[nature](#) > [toolbox](#) > [article](#)

TOOLBOX | 30 October 2018


Why Jupyter is data scientists' computational notebook of choice

An improved architecture and enthusiastic user base are driving uptake of the open-source web tool.

Особенности Python



Only Python programmers will understand 😊



Другие языки: ты можешь
сделать свой класс публичным
или приватным


Python:



Базовые типы данных в Python


teachoo

Python Data Types



Функции и классы в Python

```
1 def double(x):
2     return x * 2
3
4 def add_one(x):
5     return x + 1
6
7 print(double(add_one(1)))
8
9 # result:
10 # 4
11
```



```
class Dog:
    def __init__(self, weight, height, breed, name):
        self.weight = weight
        self.height = height
        self.breed = breed
        self.name = name

    def info(self):
        return "Hello my name is {}".format(self.name)


    def bark(self):
        return "The {} is barking".format(self.breed)

    def bmi(self):
        return int(self.weight / self.height)

Dog1 = Dog(30, 50, "golden retriever", "Terry the Legend")
Dog2 = Dog(900, 4, "poodle", "Fluffy the Amazing")

print(Dog1.info())
print(Dog1.bark())
print(Dog2.bmi())
```


Python для анализа данных



Python для анализа данных

Наиболее важные для нашего курса:

- ❑ [NumPy](#) – работа с многомерными массивами и матрицами, математические операции
- ❑ [Pandas](#) – работа табличными данными
- ❑ [Matplotlib](#) – графики на все случаи жизни с ручной настройкой
- ❑ [Scikit-learn](#) – базовый уровень машинного обучения
- ❑ [Pytorch](#) – глубокое обучение (нейросети)
- ❑ [Scipy](#) – статистический анализ


Также могут пригодиться:

- ❑ [Xarray](#) – работа с многомерными массивами данных, имеющих пространственно-временную привязку (netcdf, grib, hdf)
- ❑ [Seaborn](#) – продвинутые графики для статистического анализа
- ❑ [Rasterio](#) – работа с пространственными растровыми данными (geotiff)
- ❑ [Shapely](#), [geopandas](#) – работа с векторными пространственными данными




Многомерные массивы: NumPy

1D array




shape: (4,)

2D array




shape: (2, 3)

3D array



shape: (4, 3, 2)




Expression

`arr[:2, 1:]`

Shape

(2, 2)



`arr[2]`


(3,)

`arr[2, :]`

(3,)


`arr[2:, :]`

(1, 3)



`arr[:, :2]`

(3, 2)



`arr[1, :2]`

(2,)

`arr[1:2, :2]`

(1, 2)

Прямоугольные данные: Pandas

Ключевые термины для прямоугольных данных

Кадр данных (data frame)

Прямоугольные данные (подобно электронной таблице) — это базовая структура данных для статистических и автоматически обучающихся моделей.

Признак (feature)

Столбец в таблице обычно называется признаком.

Синонимы: атрибут, вход, предсказатель, предиктор, переменная.

Исход (outcome)

Многие проекты науки о данных предусматривают с предсказание исхода — нередко в формате да/нет (например, в табл. 1.1 это ответ на вопрос "Были ли торги состязательными или нет?"). Признаки иногда используются для предсказания исхода в эксперименте или статистическом исследовании.


Синонимы: результат, зависимая переменная, отклик, цель, выход.

Записи (records)

Строка в таблице обычно называется записью.

Синонимы: случай, пример, прецедент, экземпляр, наблюдение, шаблон, паттерн, образец.

Pandas Data structure




Конкатенация данных в Pandas


pd.concat



pd.merge





DataFrame.join



- Функция **join()** объединяет два кадра данных по индексу.
- Функция **merge()** объединяет два кадра данных по любому указанному вами столбцу.

Многомерные пространственные данные: xarray



Библиотека Xarray

<https://docs.xarray.dev/en/stable/>



Растровые геоданные: rasterio

Библиотека rasterio

File connection

```
src = rasterio.open('data/srtm.tif')
src

<open DatasetReader name='data/srtm.tif' mode='r'>
```

dict
Metadata

```
src.meta

{'driver': 'GTiff',
 'dtype': 'uint16',
 'nodata': 65535.0,
 'width': 465,
 'height': 457,
 'count': 1,
 'crs': CRS.from_epsg(4326),
 'transform': Affine(0.0008333333332777796, 0.0, -113.23958321278403,
 0.0, -0.0008333333332777843, 37.512916763165805)}
```



ndarray
Values

```
src.read(1)

array([[1728, 1718, 1715, ..., 2654, 2674, 2685],
       [1737, 1727, 1717, ..., 2649, 2677, 2693],
       [1739, 1734, 1727, ..., 2644, 2672, 2695],
       ...,
       [1326, 1328, 1329, ..., 1777, 1778, 1775],
       [1320, 1323, 1326, ..., 1771, 1770, 1772],
       [1319, 1319, 1322, ..., 1768, 1770, 1772]], dtype=uint16)
```

<https://rasterio.readthedocs.io/en/stable/#>


Векторные геоданные



 Shapely +  pandas =  GeoPandas

<https://geopandas.org/en/stable/>

Разведочный анализ данных (EDA)



Ghosh et al. (2018). A comprehensive review of tools for exploratory analysis of tabular industrial datasets. Visual Informatics 2, 235–253. <https://doi.org/10.1016/j.visinf.2018.12.004>

Перейдем к практике