

ML4hydromet-2025

Занятие №4.

Общая последовательность решения задач обучения с учителем.

Признаковое описание объектов в МО.

Проблема переобучения.

Преподаватели:

Михаил Иванович Варенцов, к.г.н.

Михаил Алексеевич Криницкий, к.т.н.




ml4hydromet@ml4es.ru




Ранее в ML4hydromet-2025

Когда (человеку) непонятно, что происходит

все равно строим модель



обобщение ?
введение абстракций ?



Ранее в ML4hydromet-2025

Когда (человеку) непонятно, что происходит

все равно строим модель

- Для чего? Какова цель?
- Что у нас для этого есть?
- Какого рода модель?
- Какая должна быть модель?
- Оценить неизвестную(ые) величину(ы) $\{y_i\}$
- Данные измерений $\{x_i\}$
- $\mathcal{F}: \mathcal{X} \rightarrow \mathcal{Y}$
- Обобщающая. Достоверная (в каком смысле?)


Применимая.

Ранее в ML4hydromet-2025

Задачи машинного обучения



Модели (алгоритмы) машинного обучения



Общая схема решения задач обучения с учителем

обучаем (тренируем) модель на имеющихся данных

«Обучение»

Объекты

признаки

	1	2	3	4	5	6	7
1	-0.0685	-0.0676	-0.0643	-0.0617	-0.0550	-0.0488	-0.0365
2	-0.0706	-0.0726	-0.0633	-0.0579	-0.0490	-0.0390	-0.0267
3	-0.0691	-0.0766	-0.0676	-0.0589	-0.0484	-0.0350	-0.0172
4	-0.0631	-0.0719	-0.0662	-0.0557	-0.0441	-0.0317	-0.0144
5	-0.0500	-0.0634	-0.0603	-0.0502	-0.0384	-0.0263	-0.0115
6	-0.0377	-0.0491	-0.0449	-0.0352	-0.0214	-0.0062	0.0056
7	-0.0375	-0.0319	-0.0235	-0.0133	0.0012	0.0169	0.0282
8	-0.0540	-0.0310	-0.0169	6.9177e-...	0.0181	0.0339	0.0445
9	-0.0725	-0.0550	-0.0158	0.0145	0.0323	0.0501	0.0641
10	-0.0789	-0.0844	-0.0512	-0.0010	0.0387	0.0612	0.0810
11	-0.0803	-0.0965	-0.0789	-0.0543	-0.0036	0.0405	0.0685
12	-0.0995	-0.1248	-0.1134	-0.0950	-0.0699	-0.0281	0.0261
13	-0.1026	-0.1306	-0.1283	-0.1171	-0.0982	-0.0806	-0.0412
14	-0.0977	-0.1284	-0.1301	-0.1188	-0.1054	-0.0932	-0.0677
15	-0.0840	-0.1133	-0.1138	-0.1040	-0.0895	-0.0750	-0.0511
16	-0.0820	-0.1089	-0.1072	-0.0967	-0.0814	-0.0669	-0.0464
17	-0.0655	-0.0685	-0.0617	-0.0595	-0.0549	-0.0499	-0.0396

Целевая
переменная

	1
1	-0.0685
2	-0.0706
3	-0.0691
4	-0.0631
5	-0.0500
6	-0.0377
7	-0.0375
8	-0.0540
9	-0.0725
10	-0.0789
11	-0.0803
12	-0.0995
13	-0.1026
14	-0.0977
15	-0.0840
16	-0.0820
17	-0.0655

Настройка параметров модели

НАСТРОЕННАЯ
МОДЕЛЬ

Модель - метод, структура, значения параметров

$$\hat{y}_i = f(\vec{p}, x_i)$$

Режим использования

новые объекты

	1	2	3	4	5	6	7	8	9
1	-0.0685	-0.0676	-0.0643	-0.0617	-0.0550	-0.0488	-0.0365	-0.0235	-0.0133
2	-0.0706	-0.0726	-0.0633	-0.0579	-0.0490	-0.0390	-0.0267	-0.0136	-0.0044
3	-0.0691	-0.0766	-0.0676	-0.0589	-0.0484	-0.0350	-0.0172	-0.0038	0.0054
4	-0.0631	-0.0719	-0.0662	-0.0557	-0.0441	-0.0317	-0.0144	-0.0022	0.0084
5	-0.0500	-0.0634	-0.0603	-0.0502	-0.0384	-0.0263	-0.0115	0.0020	0.0152
6	-0.0377	-0.0491	-0.0449	-0.0352	-0.0214	-0.0062	0.0056	0.0145	0.0238
7	-0.0375	-0.0319	-0.0235	-0.0133	0.0012	0.0169	0.0282	0.0355	0.0403

НАСТРОЕННАЯ
МОДЕЛЬ

Результат:
значения целевой
переменной

Общая схема решения задач обучения с учителем

Этап	Описание
Сбор данных	Собирают информацию из различных источников и объединяют в единый набор для обучения
Предобработка данных	Данные очищают, устраняют пропуски, удаляют выбросы и приводят к единому формату
Анализ и визуализация данных (EDA)	Данные исследуют, чтобы выявить паттерны, зависимости и аномалии и подготовить их к дальнейшей обработке
Генерация признаков (Feature Engineering)	Создают новые признаки или трансформируют исходные
Создание тренировочных и тестовых наборов данных	Данные разделяют на тренировочную и тестовую выборки для обучения и проверки модели
Выбор модели	Определяют, какой алгоритм машинного обучения будет использоваться для решения задачи
Обучение модели	Модель обучают на тренировочных данных
Оценка модели	Модель проверяют на тестовых данных, оценивают ее точность и другие метрики для определения качества
Тюнинг гиперпараметров	Настраивают гиперпараметры модели, такие как количество слоев в нейронной сети или скорость обучения. Гиперпараметры — это настройки модели, которые не изменяются в процессе обучения, но могут значительно влиять на ее производительность.
Внедрение модели (Deploy)	Модель разворачивают в продуктивной среде для использования в реальных предсказаниях

К вопросу о признаковом описании

...

Вечор, ты помнишь, вьюга злилась,
На мутном небе мгла носилась;
Луна, как бледное пятно,
Сквозь тучи мрачные желтела,
И ты печальная сидела —
А нынче... погляди в окно:

Под голубыми небесами
Великолепными коврами,
Блестя на солнце, снег лежит;
Прозрачный лес один чернеет,
И ель сквозь иней зеленеет,
И речка подо льдом блестит.

...

А.С. Пушкин, «Зимнее утро»

...

Буря мглою небо кроет,
Вихри снежные крутя;
То, как зверь, она завоет,
То заплачет, как дитя.
Выпьем, добрая подружка
Бедной юности моей,
Выпьем с горя; где же кружка?
Сердцу будет веселей.

А.С. Пушкин, «Зимний вечер»

...

Было так: Нева, как зверь, стонала,
Серые ломая гребешки,
Колыхались барки у причала,
И царапал стынувшие щеки
Острый дождь, ложась, как плащ широкий,
Над гранитным логовом реки.



...

В. Рождественский, «Октябрьская погода»

- Признаки должны быть **числами**
- Чаще всего нужно **однородное признаковое описание** (одинаковый набор признаков для всех объектов)

Решение задачи восстановления регрессии

Можем ли мы применить для этих данных линейную регрессию?



- ① $L: \mu_i = \theta^T x_i$
- ② $\mathcal{I}: i.i.d.$
- ③ $\mathcal{N}: y_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$
- ④ $\mathcal{E}: \sigma_i = \sigma$


Решение задачи восстановления регрессии: ПРИМЕР

Синтетическая задача, “toy problem”

События x_i : наблюдения циферблата часов



Признаковое описание событий $\vec{x}_i$: координаты
конца минутной стрелки

Целевая переменная m_i : минутная компонента
времени



Решение задачи восстановления регрессии: ПРИМЕР

Исследование данных: визуализация, поиск структуры



Решение задачи восстановления регрессии: ПРИМЕР

Построение и настройка модели

Возьмем очень слабую модель



Модель в задаче восстановления регрессии: $\hat{m}_i = f(\vec{p}, x_i) = kx_i + b$

Функция потерь: $\mathcal{L}(\vec{p}, \{x_i\}, \{m_i\}) = \frac{1}{n} \sum_{i=1}^n (f(\vec{p}, x_i) - m_i)^2$

Решение (оценка параметров $\vec{p}$): $\vec{p}^* = \operatorname{argmin}_{\mathbb{P}} (\mathcal{L}(\vec{p}, \{x_i\}, \{m_i\}))$

Решение задачи восстановления регрессии: ПРИМЕР

Результаты модели



Решение задачи восстановления регрессии: ПРИМЕР

Построение и настройка модели

Возьмем модель посильнее



Модель в задаче восстановления регрессии: $\hat{m}_i = f(\vec{p}, \mathbf{x}_i) = \text{poly}^{(6)}(\mathbf{x}_i)$

Функция потерь: $\mathcal{L}(\vec{p}, \{\mathbf{x}_i\}, \{\mathbf{m}_i\}) = \frac{1}{n} \sum_{i=1}^n (f(\vec{p}, \mathbf{x}_i) - \mathbf{m}_i)^2$

Решение (оценка параметров $\vec{p}$): $\vec{p}^* = \underset{\mathbb{P}}{\operatorname{argmin}}(\mathcal{L}(\vec{p}, \{\mathbf{x}_i\}, \{\mathbf{m}_i\}))$

Решение задачи восстановления регрессии: ПРИМЕР

Результаты модели



Решение задачи восстановления регрессии: ПРИМЕР

Построение и настройка модели

Возьмем нейросеть



$$\hat{\mathbf{m}}_i = MLP(\vec{\mathbf{p}}, \mathbf{x}_i)$$

$$\mathcal{L}(\vec{\mathbf{p}}, \{\mathbf{x}_i\}, \{\mathbf{m}_i\}) = \frac{1}{n} \sum_{i=1}^n (MLP(\vec{\mathbf{p}}, \mathbf{x}_i) - \mathbf{m}_i)^2$$

$$\vec{\mathbf{p}}^* = \operatorname{argmin}_{\mathbb{P}} (\mathcal{L}(\vec{\mathbf{p}}, \{\mathbf{x}_i\}, \{\mathbf{m}_i\}))$$

Решение задачи восстановления регрессии: ПРИМЕР

Результаты модели



Решение задачи восстановления регрессии: ПРИМЕР

ЧТО ЖЕ ДЕЛАТЬ?

что-то не так с постановкой задачи?

(не тот тип задачи? не та целевая переменная?)

что-то не так с признаковым описанием событий?

(нерелевантное? неполное? шумное?)

что-то не так с разметкой?

(шумная? некорректная? много? мало?)

что-то не так с моделью?

(слишком простая? слишком сложная? не подходит для этой задачи?)

что-то не так с программным кодом?

что-то не так с исследователем?


МОЖЕТ, ПРОСТО НЕТ ЗАКОНОМЕРНОСТИ?

Решение задачи восстановления регрессии: ПРИМЕР

изобретать (более информативные) признаки

Новое признаковое описание событий: $\vec{x}_i$ - угол отклонения минутной стрелки

$$x_i = \phi = \begin{cases} \arccos\left(\frac{x}{\sqrt{x^2 + y^2}}\right), & \text{если } x \geq 0 \\ 2\pi - \arccos\left(\frac{x}{\sqrt{x^2 + y^2}}\right), & \text{если } x < 0 \end{cases}$$



Решение задачи восстановления регрессии: ПРИМЕР

Построение и настройка модели

Возьмем очень слабую модель

Модель в задаче восстановления регрессии: $\hat{m}_i = f(\vec{p}, \phi_i) = k\phi_i + b$

Функция потерь:


$$\mathcal{L}(\vec{p}, \{\phi_i\}, \{m_i\}) = \frac{1}{n} \sum_{i=1}^n (f(\vec{p}, \phi_i) - m_i)^2$$

Решение (оценка параметров $\vec{p}$):

$$\vec{p}^* = \operatorname{argmin}_{\mathbb{P}} (\mathcal{L}(\vec{p}, \{\phi_i\}, \{m_i\}))$$

Решение задачи восстановления регрессии: ПРИМЕР

Результаты модели



Решение задачи восстановления регрессии: ПРИМЕР

использовать (более) полную информацию о событиях

Новое признаковое описание событий: $\vec{x}_i$ - обе координаты x, y конца минутной стрелки

Возьмем нейросеть

$$\hat{m}_i = MLP(\vec{p}, \vec{x}_i)$$

$$\mathcal{L}(\vec{p}, \{\vec{x}_i\}, \{m_i\}) = \frac{1}{n} \sum_{i=1}^n (MLP(\vec{p}, \vec{x}_i) - m_i)^2$$


$$\vec{p}^* = \underset{\mathbb{P}}{\operatorname{argmin}} (\mathcal{L}(\vec{p}, \{\vec{x}_i\}, \{m_i\}))$$

Качество модели: $RMSE = 0.28m$

Конструирование признаков


Можно и нужно порождать (изобретать, конструировать) новые признаки, в т.ч. с учетом наших экспертных знаний.

Конструирование признаков (трансформация и создание, feature engineering) это важная часть процесс разработки ML-модели.



Преобразования (трансформация) признаков

- ❑ **Масштабирование (scaling)**, приведение признаков к единому масштабу – важно для моделей, использующих меру расстояния
 - Стандартизация (Standardization / Z-score normalization):
 $(x - \text{mean}) / \text{std}$
 - Нормализация (Normalization / Min-Max scaling):
 $(x - \text{min}) / (\text{max} - \text{min})$
 - Робастное масштабирование
 $(x - \text{median}) / \text{IQR}$
- ❑ **Преобразования распределения:**
 - Логарифмирование (Log Transformation)
 - Возведение в степень
- ❑ **Трансформации для категориальных признаков** - важна для параметрических моделей, где требуется числовое представление
 - **one-hot кодирование:** для каждой категории создаётся отдельный бинарный признак (1 — категория присутствует, 0 — отсутствует)



Общая схема решения задач обучения с учителем

1. формулировка задачи:

- какой тип (классификация, регрессия, другой)? Или переформулировать в легко решаемый тип!
- определиться, что есть объекты (события)
- определиться, что есть целевая переменная
- определить признаковое описание объектов (событий)
- определить критерии качества решения задачи (MSE, MAE, pattern correlation, etc.)

2. сформулировать модель:

- вид модели (линейная регрессия, дерево решений, композиционный алгоритм, нейронная сеть, etc.)
- определиться с функцией потерь (MSE, MAE, BCE, CCE, etc., комбинации)
- сложность модели (задается гиперпараметрами – настройками модели)

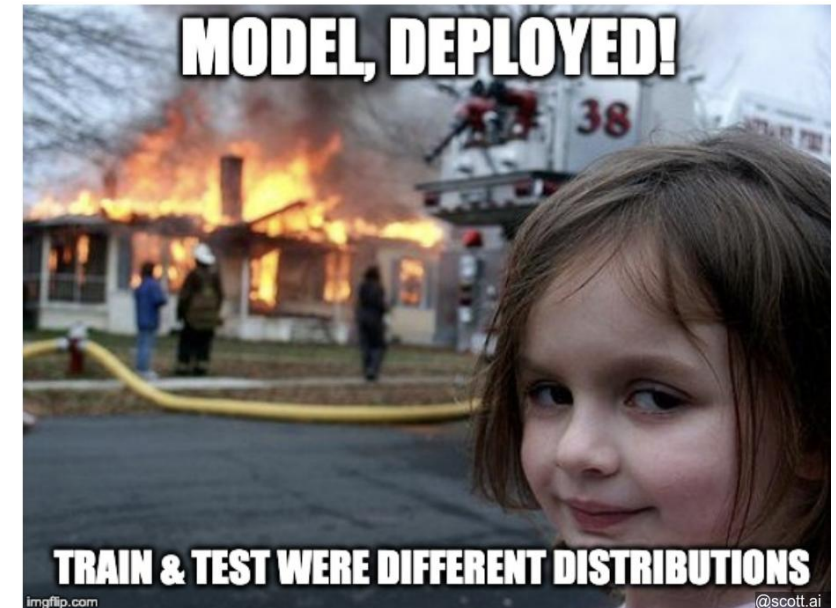
Общая схема решения задач обучения с учителем

3. подготовить данные или генератор данных:
 - обработка пропусков, категориальных значений, кодирование текста, понижение размерности данных и другие преобразования
 - масштабировать данные (если нужно)
 - оставить часть данных для проверки качества (train-validation-test split)
 - **подготовить генератор данных с учетом стратегии скользящего контроля (cross-validation quality estimation)**
4. оптимизировать модель на обучающей выборке:
 - $\hat{p} = \underset{\mathbb{P}}{\operatorname{argmin}}(L(\vec{p}, \mathcal{T}))$
5. оптимизация гиперпараметров модели и отбор моделей. Провизодится по значениям метрик качества на контрольной(контрольных) выборке(выборках)
6. оценка модели:
 - оценить качество по метрикам, определенным на этапе 1. на тестовой выборке
 - оценить неопределенность параметров модели (если возможно)
 - оценить неопределенность оценок целевой переменной

Общая схема решения задач обучения с учителем

6. применение модели на вновь получаемых данных:

- оценка распределения вновь получаемых данных: генерируются ли они из того же распределения, что и обучающая выборка?
- предобработка новых данных идентично п.3 с точностью до коэффициентов стандартизации и деталей способов предобработки
- применение модели к предобработанным новым данным для получения значений целевой переменной
- построение научных выводов, описание их в виде статей, получение наград в виде Нобелевских премий, etc.





Общая схема решения задач обучения с учителем

Этап	Описание
Сбор данных	Собирают информацию из различных источников и объединяют в единый набор для обучения
Предобработка данных	Данные очищают, устраняют пропуски, удаляют выбросы и приводят к единому формату
Анализ и визуализация данных (EDA)	Данные исследуют, чтобы выявить паттерны, зависимости и аномалии и подготовить их к дальнейшей обработке
Генерация признаков (Feature Engineering)	Создают новые признаки или трансформируют исходные
Создание тренировочных и тестовых наборов данных	Данные разделяют на тренировочную и тестовую выборки для обучения и проверки модели
Выбор модели	Определяют, какой алгоритм машинного обучения будет использоваться для решения задачи
Обучение модели	Модель обучают на тренировочных данных
Оценка модели	Модель проверяют на тестовых данных, оценивают ее точность и другие метрики для определения качества
Тюнинг гиперпараметров	Настраивают гиперпараметры модели, такие как количество слоев в нейронной сети или скорость обучения. Гиперпараметры — это настройки модели, которые не изменяются в процессе обучения, но могут значительно влиять на ее производительность.
Внедрение модели (Deploy)	Модель разворачивают в продуктивной среде для использования в реальных предсказаниях

Техническая реализация в sklearn

Scikit-Learn Methods for Machine Learning



Домашнее задание №3. Линейная регрессия.

В задании необходимо:

- На основе выбранной коллекции данных подготовить массивы целевой переменной (Y) и признакового описания (X)
- Разделить набор данных на тестовую и тренировочную выборки
- Выполнить на основе подготовленных данных оптимизацию (fit) модели линейной или логистической регрессии, используя реализацию LinearRegression/LogisticRegression библиотеки из scikit-learn
- Проанализировать качество построенной модели для тестовой и тренировочной выборок, используя выбранные метрики качества и графические средства анализа на ваше усмотрение (тут можно проявить фантазию)
- Проанализировать влияние масштабирования признаков на качество модели
- Реализовать порождение новых признаков и проанализировать их влияние на качество модели
- Выполнить первичный анализ и интерпретацию полученных коэффициентов регрессии (θ в терминологии нашего курса).
- **Нельзя использовать пайплайны и готовые функции для кросс-валидации**