

ML4hydromet-2025

Занятие №5.

Неопределенность в машинном обучении. Кросс-валидация.

Преподаватели:




Михаил Иванович Варенцов, к.г.н.

Михаил Алексеевич Криницкий, к.т.н.

ml4hydromet@ml4es.ru



Валидация на отложенных данных




Кросс-валидация

Скользящий контроль или кросс-проверка или кросс-валидация (cross-validation, CV)

- Hold-out
- k-Fold
- Stratified k-Fold
- Blocked k-Fold
- Leave-one-out (Jackknife)
- Bootstrap
- ...

<https://allmodelsarewrong.github.io/resampling.html>

K-Fold



Bootstrap




Кросс-валидация

Скользящий контроль или кросс-проверка или кросс-валидация
(cross-validation, CV)

- Hold-out
- k-Fold
- Stratified k-Fold
- Blocked k-Fold
- Leave-one-out (Jackknife)
- Bootstrap
- ...

<https://amueller.github.io/aml/04-model-evaluation/1-data-splitting-strategies.html>



Кросс-валидация

Особенности кросс-валидации в гидрометеорологии:

- Автокорреляция (зависимость последовательных событий)
- Суточный и сезонный ход
- Нестационарность условий
(изменения климата, антропогенное воздействие, урбанизация)
- Экстремальные события
- ...


Пример: аппроксимация острова тепла

❏ **The dataset:**

- time series with 3-hour step for 47 years (1977-2021)
- 21 years (2001-2021) are used to train the models and for the major part of analysis

- ❑ **Train-test split using blocked k-fold method with 5-days blocks and 4:1 train-to-test ratio**

- ❑ **Model quality metrics: RMSE, ME, R^2**




Varentsov M., Krinitskiy M., Stepanenko V. Machine learning for simulation of urban heat island dynamics based on large-scale meteorological conditions // *CLIMATE*. — 2023. — Vol. 11, no. 10. — P. 200.

Реализация в sklearn

Иерархия классов в sklearn

- Estimator
 - Transformer
 - StandardScaler
 - ...
 - Predictor
 - LinearRegression
 - ...
 - Pipeline
- CrossValidator
 - ShuffleSplit
 - KFold



cross_validate

```
sklearn.model_selection.cross_validate(estimator, X, y=None, *, groups=None,
scoring=None, cv=None, n_jobs=None, verbose=0, params=None,
pre_dispatch='2*n_jobs', return_train_score=False, return_estimator=False,
return_indices=False, error_score=nan)
```

[\[source\]](#)

Домашнее задание №4*

В задании необходимо:

1. Дополнить решение выбранной вами задачи машинного обучения методом линейной регрессии реализацией подхода кросс-валидации. При это нужно обосновать выбор оптимального метода кросс-валидации для вашей задачи (bootstrap, k-fold, stratified k-fold и т.д.). Можно использовать как готовые решения из библиотеки `scikit-learn`, так и реализовать алгоритм кросс-валидации самостоятельно.
2. С использованием выбранного подхода кросс-валидации оценить неопределенность (в терминах выбранной вами **меры неопределенности**, которую нужно явно обозначить - например, стандартное отклонение, доверительные интервалы заданного уровня значимости и пр.):
 - метрик качества модели
 - параметров модели (коэффициентов регрессии θ для наиболее важных, на ваш взгляд, предикторов)
 - результатов расчета целевой переменной для выбранного события/событий (например, для показательного временного периода)
3. Сравнить метрики качества модели и их неопределенность при использовании как минимум одного альтернативного метода кросс-валидации (например, сравнить выбранный вами метод со стандартным `shuffle split`)
4. В рамках подхода кросс-валидации исследовать, являются ли следующие изменения метрик качества модели при следующих преобразованиях исходных данных статистически значимыми:
 - масштабирования данных (стандартизации или нормализации)
 - порождения новых признаков
5. **Бонусная часть:** Реализовать алгоритм генерации тренировочных и тестовых выборок данных для выбранного вами метода кросс-валидации как класс с методом-генератором `split`, совместимый с функциями `cross_val_score` и `cross_validate` библиотеки `scikit-learn`.

* Можно сдавать как расширенную версию задания №3

Перейдем к практике

