




Машинное обучение в гидрометеорологии

М.А. Криницкий

ЗАДАЧИ МАШИННОГО ОБУЧЕНИЯ

типы задач:

- «Обучение без учителя»
 - снижение размерности



ЗАДАЧИ МАШИННОГО ОБУЧЕНИЯ

типы задач:

○ «Обучение без учителя»


- снижение размерности

что я хочу?

признаковое описание
сниженной размерности


зачем?

- визуализация данных
- снижение вычислительных затрат
- борьба с «проклятием размерности»
- снижение уровня шума в данных



Снижение размерности: PCA

- Метод главных компонент (PCA, principal components analysis)



1. Стандартизировать признаки: $\tilde{X}$
2. Рассчитать матрицу ковариаций (стандартизованных) признаков $\tilde{X}$
3. Найти собственные векторы и собственные значения матрицы ковариаций (стандартизованных) признаков
 1. собственные векторы – направления максимальной дисперсии данных
 2. собственные значения – величина объясненной дисперсии данных для компоненты
4. Отсортировать собственные векторы по убыванию собственных значений
5. Отобрать top-k векторов и значений, в сумме объясняющих заданную долю дисперсии в данных, составить матрицу главных компонент W
6. Спроецировать данные на векторы top-k главных компонент: $Z = XW$

Снижение размерности: UMAP

Uniform Manifold Approximation and Projection (UMAP)

- Строит граф данных (каждый объект коллекции – узел графа) на основании близости.
 - К каждому объекту находятся K ближайших соседей согласно метрике в пространстве оригинальных признаков;
 - граф составляется из ребер, которым присваиваются веса согласно дистанциям: $w_{ij} = \exp(-\frac{d_{ij}}{\sigma_i})$
- Строит граф в низкоразмерном пространстве (2D, 3D), по структуре соответствующий графу в высокоразмерном пространстве признаков; узлы произвольно расположены в пространстве;
- Расположение точек в низкоразмерном пространстве оптимизируется:
 - минимизируется отклонение весов в высокоразмерном и низкоразмерном пространствах)
 - процедура оптимизации – итерационная
 - учитываются «силы притяжения» для объектов, расположенных близко и «силы отталкивания» для удаленных объектов

UMAP: свойства и ограничения

- Сохраняет локальную структуру и кластера, удобен для визуализации
- Зависит от параметров (`n_neighbors`, `min_dist`), чувствителен к масштабам признаков
- Не проецирует новые данные напрямую (нужен отдельный аппроксиматор)
- Метрика (обычно евклидова) задаётся извне, а не учится из данных

Фиксированная метрика — проблема

- Евклидово расстояние между полями не учитывает физическую структуру атмосферы/океана (смещение, вращение паттернов...)
- PCA и UMAP используют экспертно заданную метрику и не адаптируются к задаче, свойствам данных
- Хотим, чтобы понимание близости выучивалось моделью: близкими должны быть объекты (поля, снимки, etc.) с похожими физическими свойствами

Задача выучивания метрики

- Выучивание метрики: **на основе данных** выучим преобразование (функцию, нейросеть), позволяющее вычислять векторы скрытых представлений («**эмбеддинги**»), которые **близки для схожих объектов, далеки для непохожих**.
- Для этого:
 - эксперт задает правило «эти объекты похожи»;
 - должно выполняться правило «два произвольных объекта – весьма вероятно непохожи»; или эксперт задает правило «эти объекты - непохожи»;
 - задается функция, определяющая ошибку нейросети при классификации «похожий - непохожий»

Задача выучивания метрики

- UMAP: формула близости объектов в высокоразмерном пространстве задается экспертно
- Выучивание метрики: формула близости объектов в высокоразмерном пространстве – нейросеть, обучается **на основе данных**

Задача выучивания метрики

- Выучивание метрики: **на основе данных** выучим преобразование (функцию, нейросеть), позволяющее вычислять векторы скрытых представлений («**эмбеддинги**»), которые **близки для схожих объектов, далеки для непохожих**.
- Для этого:
 - эксперт задает правило «эти объекты похожи»;
 - должно выполняться правило «два произвольных объекта – весьма вероятно непохожи»; или эксперт задает правило «эти объекты - непохожи»;
 - задается функция, определяющая ошибку нейросети при классификации «похожий - непохожий»

Контрастное обучение

- Положительная пара: объекты, которые должны быть близко
- Отрицательная пара: объекты, которые должны быть далеко

SimCLR

- Концептуально прост
- Простая обработка данных
- Одна нейросеть
- Хорошо работает только при больших размерах `batch_size ~ 256-4096`
- SimCLR плохо работает при малых батчах, а для большинства реальных задач сложно организовать большие батчи
- => не рассчитан на ограниченные аппаратные ресурсы (GPU)

MoCo

- MoCo - это реализация InfoNCE, в которой позитив и негатив вычисляются через «запаздывающую», стабильную momentum-нейросеть; опорный пример вычисляется через базовую нейросеть
- Хорошо работает при малых размерах batch_size
- Momentum encoder обеспечивает консистентность эмбеддингов, снижает шум и делает контрастное обучение намного устойчивее